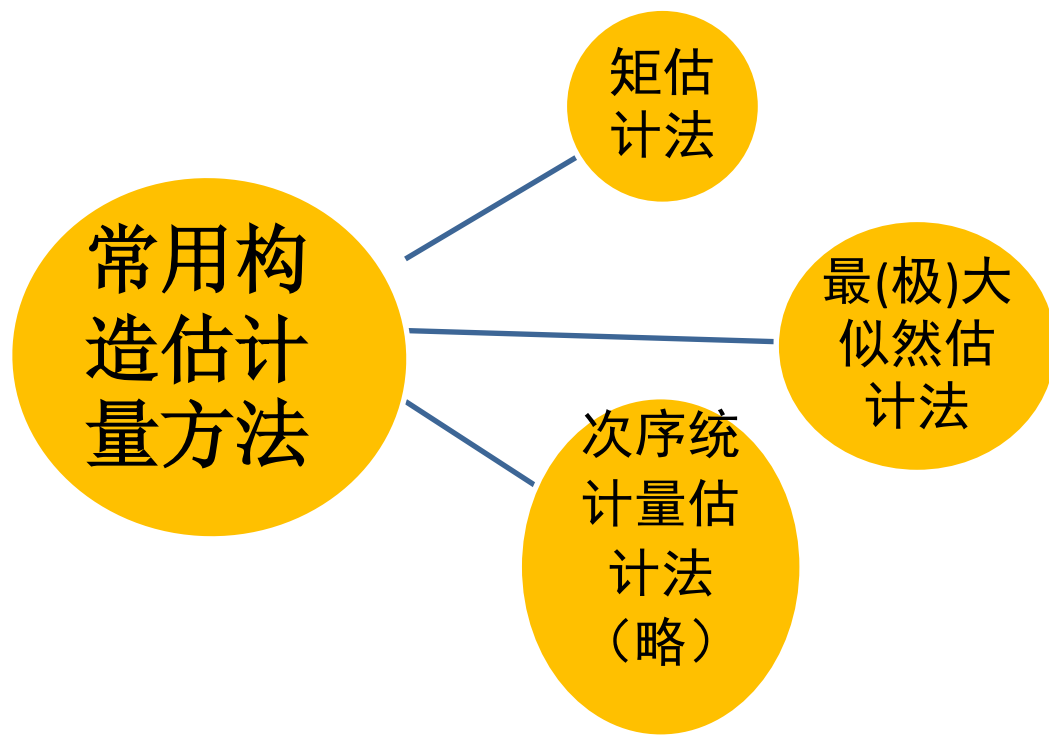




2.2 点估计量的求法

由于估计量是样本的函数, 是随机变量, 故对不同的样本值, 得到的参数值往往不同, 因此如何求得参数 θ 的估计量便是问题的关键所在.





一、矩估计法

1. 矩估计法

是基于一种简单的“替换”思想建立起来的一种估计方法。

是英国统计学家K.皮尔逊最早提出的。



基本思想：用**样本矩**估计**总体矩**。

理论依据：大数定律



记总体 k 阶原点矩为 $\alpha_k = E(X^k)$

样本 k 阶原点矩为 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$

记总体 k 阶中心矩为 $\mu_k = E[X - E(X)]^k$

样本 k 阶中心矩为 $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$

用样本矩来估计总体矩，这种估计法称为矩估计法.



设总体 X 的分布函数为 $F(x; \theta_1, \theta_2, \cdots, \theta_m)$

m 个待估参数 (未知)

$\alpha_k = E(X^k)$ 存在 ($k = 1, 2, \cdots, m$), (X_1, X_2, \cdots, X_n)


为来自总体 X 的简单随机样本.

矩估计法的具体步骤:

1° 求出 $\alpha_k = E(X^k) = \alpha(\theta_1, \theta_2, \cdots, \theta_m)$, $k = 1, 2, \cdots, m$;

2° 要求: $\alpha_k = A_k$, $k = 1, 2, \cdots, m$

这是一个包含 m 个未知参数 $\theta_1, \theta_2, \cdots, \theta_m$ 的方程组.



3° 解出其中 $\theta_1, \theta_2, \dots, \theta_m$, 用 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 表示.

4° 用方程组的解 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 分别作为 $\theta_1, \theta_2, \dots, \theta_m$ 的估计量, 这个估计量称为矩估计量.

矩估计量的观察值称为矩估计值.


注 若 $\hat{\theta}_k$ 是 θ_k 的矩估计, $g(\theta)$ 为连续函数, 则也称 $g(\hat{\theta}_k)$ 是 $g(\theta_k)$ 的矩估计.

即用样本矩的函数来估计总体矩的函数.



例1 设总体 X 在 $[0, \theta]$ 上服从均匀分布, 其中 θ ($\theta > 0$) 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 θ 的矩估计量.

证 因为 $\alpha_1 = E(X) = \frac{\theta}{2}$,
根据矩估计法, 令 $\frac{\theta}{2} = A_1 = \bar{X}$,
所以 $\hat{\theta} = 2\bar{X}$ 为所求 θ 的估计量.



例2 设总体 X 在 $[\theta_1, \theta_2]$ 上服从均匀分布, 其中 θ_1, θ_2 未知, (X_1, X_2, \dots, X_n) 是来自总体 X 的样本, 求 θ_1, θ_2 的矩估计量.

证

$$\alpha_1 = E(X) = \frac{\theta_1 + \theta_2}{2},$$
$$\alpha_2 = E(X^2) = D(X) + [E(X)]^2$$
$$= \frac{(\theta_2 - \theta_1)^2}{12} + \frac{(\theta_1 + \theta_2)^2}{4},$$

$$\text{令 } \frac{\theta_1 + \theta_2}{2} = A_1 = \frac{1}{n} \sum_{i=1}^n X_i,$$

$$\frac{(\theta_2 - \theta_1)^2}{12} + \frac{(\theta_1 + \theta_2)^2}{4} = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2,$$




$$\text{即} \begin{cases} \theta_1 + \theta_2 = 2A_1, \\ \theta_2 - \theta_1 = \sqrt{12(A_2 - A_1^2)}, \end{cases}$$

解方程组得到 θ_2, θ_1 的矩估计量分别为

$$\hat{\theta}_1 = A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$

$$\hat{\theta}_2 = A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2},$$



例3 设总体 X 的均值 μ 和方差 σ^2 都存在, 且有 $\sigma^2 > 0$, 但 μ 和 σ^2 均为未知, 又设 X_1, X_2, \dots, X_n 是一个样本, 求 μ 和 σ^2 的矩估计量.

解 $\alpha_1 = E(X) = \mu,$

$$\alpha_2 = E(X^2) = D(X) + [E(X)]^2 = \sigma^2 + \mu^2,$$

$$\text{令} \begin{cases} \mu = A_1 \\ \sigma^2 + \mu^2 = A_2 \end{cases}$$

解方程组得到矩估计量分别为 $\hat{\mu} = A_1 = \bar{X},$

$$\hat{\sigma}^2 = A_2 - A_1^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2.$$



上例表明:

总体均值与方差的矩估计量的表达式不因不同的总体分布而异.

例 $X \sim N(\mu, \sigma^2)$, μ, σ^2 未知, 即得 μ, σ^2 的矩估计量

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

一般地:

用样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 作为总体 X 的均值的矩估计,

用样本二阶中心矩 $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 作为总体

X 的方差的矩估计.



例4 设总体 X 的分布密度为


$$p(x; \theta) = \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} \quad (x \in R, \theta > 0)$$

(X_1, X_2, \dots, X_n) 为来自总体 X 的样本. 求参数 θ 的矩估计量.

分析: $p(x; \theta)$ 中只含有一个未知参数 θ , 一般地,

只需要求: $E(X) = \alpha_1 = A_1 = \bar{X} \Rightarrow \theta$ 的矩估计量.

然而 $E(X) = \int_{-\infty}^{+\infty} x p(x; \theta) dx$



然而 $E(X) = \int_{-\infty}^{+\infty} x p(x; \theta) dx$

$$= \int_{-\infty}^{+\infty} x \cdot \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} dx = 0$$

不含有 θ , 故不能由此得到 θ 的矩估计量.


解(方法1) 要求: $E(X^2) = \alpha_2 = A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$

$$\therefore E(X^2) = \int_{-\infty}^{+\infty} x^2 p(x; \theta) dx$$

$$= \int_0^{+\infty} x^2 \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = 2\theta^2.$$

$$\therefore \hat{\theta} = \sqrt{\frac{1}{2n} \sum_{i=1}^n X_i^2}$$

— θ 的矩估计量



(方法2) 要求:

$$E(|X|) = \frac{1}{n} \sum_{i=1}^n |X_i|$$

$$\begin{aligned} \therefore E(|X|) &= \int_{-\infty}^{+\infty} |x| p(x; \theta) dx = \int_{-\infty}^{+\infty} |x| \cdot \frac{1}{2\theta} e^{-\frac{|x|}{\theta}} dx \\ &= \int_0^{+\infty} x \cdot \frac{1}{\theta} e^{-\frac{x}{\theta}} dx = \left(-x e^{-\frac{x}{\theta}} \right) \Big|_0^{+\infty} + \int_0^{+\infty} e^{-\frac{x}{\theta}} dx = \theta \end{aligned}$$

$$\therefore \theta \text{ 的矩估计量: } \hat{\theta} = \frac{1}{n} \sum_{i=1}^n |X_i|$$

注 此例表明: 同一参数的矩估计量可不唯一.



例5(p43例2.9)已知水文站最高水位 X 服从 $\Gamma(\alpha, \beta)$,

$$f(x; \alpha, \beta) = \begin{cases} \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, & x > 0, \\ 0, & x \leq 0, \end{cases}$$

其中未知参数 $\alpha > 0, \beta > 0$, 试求 α, β 的矩估计

解 由 Γ 分布的性质1可知,

$$E(X) = \frac{\alpha}{\beta}, \quad E(X^2) = \frac{(\alpha+1)\alpha}{\beta^2},$$

建立方程



$$\begin{cases} \frac{\alpha}{\beta} = \bar{X}, \\ \frac{(\alpha+1)\alpha}{\beta^2} = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases}$$

求解方程可得

$$\hat{\alpha} = \frac{\bar{X}^2}{S_n^2}, \quad \hat{\beta} = \frac{\bar{X}}{S_n^2}$$



小结： 矩法的**性质**：矩估计一定是相合估计。

矩法的**优点**：简单易行, 并不需要事先知道总体是什么分布。

缺点：当总体类型已知时，没有充分利用分布提供的信息。
有时候，矩估计量不唯一。

其主要原因在于建立矩法方程时，选取哪些总体矩用相应样本矩代替带有一定的随意性。



二、最大似然估计法


(Maximum-likelihood Estimation)

最大似然估计法是在总体类型已知条件下使用的一种参数估计方法。

它首先是由德国数学家高斯在1821年提出的，


然而，这个方法常归功于英国统计学家Fisher。

Fisher在1921年重新发现了这一方法，并首先研究了这种方法的一些性质。





1 最大似然法的基本思想

引例1： 有两个外形完全相同的箱子，



甲箱中有99只白球，1只黑球；乙箱中有99只黑球，1只白球；一次试验取出一球，结果取出的是黑球。

问：黑球从哪个箱子中取出？



我们的第一印象就是：此黑球**最像**是从乙箱中取出的。

这个推断符合人们的经验事实。


“**最像**” 就是 “**最大似然**” 之意。



引例2： 有一个箱子，



or



箱中要么有99只白球，1只黑球；要么有99只黑球，1只白球；从箱中任取出一球，是黑球。

问：估算箱子中的黑球数目是99只还是1只？



上问题可以转化为

$X \sim B(1, p)$, p 表示取得黑球 $\{X = 1\}$ 的概率,
通过试验结果来估算 $p = 0.01$ *or* 0.99 .

显然 p 最可能取 0.99 .

$p = 0.99$ 使 $P\{X = 1\} = p^1(1-p)^{1-1} = p = 0.99$

在 p 的两个取值 0.01 和 0.99 中达到最大.

一次试验中概率值最大的那个事件最有可能发生。
哪个参数值使得发生事件的概率值最大，参数
就最可能取哪个值。



引例3 设 $X \sim B(1, p)$, p 未知. 设想我们事先知道 p 只有两种可能:

$$p=0.7 \quad \text{或} \quad p=0.3$$

如今重复试验3次,得结果: 0, 0, 0

问: 应如何估计 p ?

解 问题可以转化为

总体 $X \sim B(1, p)$, p 表示 $\{X = 1\}$ 的概率,

通过试验结果来估算 $p = 0.7 \text{ or } 0.3$.



这里重复试验3次, 得结果: 0, 0, 0,

相当于从总体中取得一个样本容量为3的样本。

样本的联合分布律

$$\begin{aligned} P\{X_1 = x_1, X_2 = x_2, X_3 = x_3\} &= \prod_{i=1}^3 p^{x_i} (1-p)^{1-x_i} \\ &= p^{x_1+x_2+x_3} (1-p)^{3-(x_1+x_2+x_3)} \end{aligned}$$

$$\begin{aligned} P\{X_1 = 0, X_2 = 0, X_3 = 0\} &= p^0 (1-p)^{3-0} = (1-p)^3 \\ &= L(p) \text{ 应该最大} \end{aligned}$$

显然 $L(0.3) > L(0.7)$, 所以 $\hat{p} = 0.3$.

参数的估计值跟样本值有关。



2 似然函数

(1) 设总体是离散型

设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值.

则样本 X_1, X_2, \dots, X_n 取到观察值 x_1, x_2, \dots, x_n 的概率

即事件 $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$ 发生的概率为

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta), \quad \theta \in \Theta$$

$L(\theta)$ 称为样本似然函数.



最大似然估计法

得到样本值 x_1, x_2, \dots, x_n 时, 选取使似然函数 $L(\theta)$

取得最大值的 $\hat{\theta}$ 作为未知参数 θ 的估计值,

即
$$L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta).$$

这样得到的 $\hat{\theta}$ 与样本值 x_1, x_2, \dots, x_n 有关, 记为

$\hat{\theta}(x_1, x_2, \dots, x_n)$, 参数 θ 的最大似然估计值,

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 参数 θ 的最大似然估计量.



(2) 设总体是连续型


似然函数的定义

设概率密度为 $f(x; \theta)$, θ 为待估参数, $\theta \in \Theta$

X_1, X_2, \dots, X_n 是来自总体 X 的样本,

则 X_1, X_2, \dots, X_n 的联合密度为 $\prod_{i=1}^n f(x_i; \theta)$.

又设 x_1, x_2, \dots, x_n 为相应于样本 X_1, X_2, \dots, X_n 的一个样本值.



则随机点 (X_1, X_2, \dots, X_n) 落在点 (x_1, x_2, \dots, x_n) 的邻域(边长分别为 dx_1, dx_2, \dots, dx_n 的 n 维立方体)内的概率近似地为 $\prod_{i=1}^n f(x_i; \theta) dx_i = \prod_{i=1}^n f(x_i; \theta) \underbrace{\prod_{i=1}^n dx_i}_{\text{固定}}$,

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta),$$

$L(\theta)$ 称为样本的似然函数.

若 $L(x_1, x_2, \dots, x_n; \hat{\theta}) = \max_{\theta \in \Theta} L(x_1, x_2, \dots, x_n; \theta)$.

$\hat{\theta}(x_1, x_2, \dots, x_n)$ 参数 θ 的最大似然估计值

$\hat{\theta}(X_1, X_2, \dots, X_n)$ 参数 θ 的最大似然估计量



3. 求最大似然估计的步骤


(一) 写出似然函数

$$L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n p(x_i; \theta)$$

$$\text{或 } L(\theta) = L(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta);$$

(二) 取对数

$$\ln L(\theta) = \sum_{i=1}^n \ln p(x_i; \theta) \quad \text{或} \quad \ln L(\theta) = \sum_{i=1}^n \ln f(x_i; \theta);$$




(三) 对 θ 求导 $\frac{d \ln L(\theta)}{d \theta}$, 并令 $\frac{d \ln L(\theta)}{d \theta} = 0$, 对数似然方程

解方程即得未知参数 θ 的最大似然估计值 $\hat{\theta}$.

最大似然估计法也适用于分布中含有多个未知参数的情况. 此时只需令

$$\frac{\partial}{\partial \theta_i} \ln L = 0, \quad i = 1, 2, \dots, k. \quad \text{对数似然方程组}$$

解出由 k 个方程组成的方程组, 即可得各未知参数 θ_i ($i = 1, 2, \dots, k$) 的最大似然估计值 $\hat{\theta}_i$.



例6 (p46例2.12) 设 X 服从参数为 λ ($\lambda > 0$) 的泊松分布, X_1, X_2, \dots, X_n 是来自 X 的一个样本, 求 λ 的最大似然估计量.

解 因为 X 的分布律为

$$P\{X = x\} = \frac{\lambda^x}{x!} e^{-\lambda} \quad (x = 0, 1, 2, \dots)$$

所以 λ 的似然函数为

$$L(\lambda) = \prod_{i=1}^n \left(\frac{\lambda^{x_i}}{x_i!} e^{-\lambda} \right) = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n (x_i!)},$$



$$\ln L(\lambda) = -n\lambda + \left(\sum_{i=1}^n x_i \right) \ln \lambda - \left[\sum_{i=1}^n \ln(x_i!) \right],$$

$$\text{令 } \frac{d}{d\lambda} \ln L(\lambda) = -n + \frac{\sum_{i=1}^n (x_i)}{\lambda} = 0,$$

$$\text{解得 } \lambda \text{ 的最大似然估计值 } \lambda = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$$

$$\lambda \text{ 的最大似然估计量为 } \hat{\lambda} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}.$$

这一估计量与矩估计量是相同的.




例7 (p47例2.13) 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, x_1, x_2, \dots, x_n 是来自 X 的一个样本值, 求 μ 和 σ^2 的最大似然估计量.

解 X 的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

X 的似然函数为


$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}},$$


$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

$$\text{令} \begin{cases} \frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = 0 \\ \frac{\partial}{\partial \sigma^2} \ln L(\mu, \sigma^2) = 0 \end{cases}$$

$$\begin{cases} \frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0, \end{cases}$$





由 $\frac{1}{\sigma^2} \left[\sum_{i=1}^n x_i - n\mu \right] = 0$ 解得 $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$

由 $-\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0$ 解得

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2,$$

故 μ 和 σ^2 的最大似然估计量分别为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

它们与相应的
矩估计量相同.




例7-1 设总体 $X \sim N(\mu, \sigma^2)$, μ 为已知参数, σ^2 为未知参数, x_1, x_2, \dots, x_n 是来自 X 的一个样本值, 求 σ^2 的最大似然估计量.

解 X 的概率密度为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}},$$

X 的似然函数为

$$L(\mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}},$$


$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2,$$

$$\text{令 } \frac{d}{d\sigma^2} \ln L(\sigma^2) = 0,$$

$$-\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 = 0,$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \mu)^2,$$

故当 μ 已知时, σ^2 的最大似然估计为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2.$$





? 矩估计和最大似然估计结果一样吗

例8(p48例2.15) 设总体 X 在 $[\theta_1, \theta_2]$ 上服从均匀分布, 其中 θ_1, θ_2 未知, x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值, 求 θ_1, θ_2 的最大似然估计量.

解 记 $x_{(1)} = \min(x_1, x_2, \dots, x_n),$
 $x_{(n)} = \max(x_1, x_2, \dots, x_n),$

X 的概率密度为

$$f(x; \theta_1, \theta_2) = \begin{cases} \frac{1}{\theta_2 - \theta_1}, & \theta_1 \leq x \leq \theta_2 \\ 0, & \text{其它} \end{cases}$$






因为 $\theta_1 \leq x_1, x_2, \dots, x_n \leq \theta_2$ 等价于 $\theta_1 \leq x_{(1)}, x_{(n)} \leq \theta_2$,

作为 θ_1, θ_2 的函数的似然函数为

$$L(\theta_1, \theta_2) = \begin{cases} \frac{1}{(\theta_2 - \theta_1)^n}, & \theta_1 \leq x_{(1)}, x_{(n)} \leq \theta_2 \\ 0, & \text{其它} \end{cases}$$

于是对于满足条件 $\theta_1 \leq x_{(1)}, \theta_2 \geq x_{(n)}$ 的任意 θ_1, θ_2 有

$$L(\theta_1, \theta_2) = \frac{1}{(\theta_2 - \theta_1)^n} \leq \frac{1}{(x_{(n)} - x_{(1)})^n},$$



即似然函数 $L(\theta_1, \theta_2)$ 在 $\theta_1 = x_{(1)}$, $\theta_2 = x_{(n)}$ 时
取到最大值 $(x_{(n)} - x_{(1)})^{-n}$,
 θ_1, θ_2 的最大似然估计值

$$\hat{\theta}_1 = x_{(1)} = \min_{1 \leq i \leq n} x_i, \quad \hat{\theta}_2 = x_{(n)} = \max_{1 \leq i \leq n} x_i,$$

θ_1, θ_2 的最大似然估计量

$$\hat{\theta}_1 = \min_{1 \leq i \leq n} X_i, \quad \hat{\theta}_2 = \max_{1 \leq i \leq n} X_i.$$

矩估计

$$\begin{aligned} \hat{\theta}_1 &= A_1 - \sqrt{3(A_2 - A_1^2)} = \bar{X} - \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}, \\ \hat{\theta}_2 &= A_1 + \sqrt{3(A_2 - A_1^2)} = \bar{X} + \sqrt{\frac{3}{n} \sum_{i=1}^n (X_i - \bar{X})^2}, \end{aligned}$$

最大似然估计与矩估计不同!



例9 设总体 X 在 $[\theta, \theta+1]$ 上服从均匀分布, 其中 θ 未知, x_1, x_2, \dots, x_n 是来自总体 X 的一个样本值, 求 θ 的最大似然估计量.

解 X 的概率密度为

$$f(x; \theta) = \begin{cases} 1, & \theta \leq x \leq \theta+1 \\ 0, & \text{其它} \end{cases}$$

$$L(\theta) = \begin{cases} 1, & \theta \leq x_{(1)}, x_{(n)} \leq \theta+1, \\ 0, & \text{其它} \end{cases}$$



似然函数在不为零的区域上是常数。

那么，只要 θ 不超过 $x_{(1)}$ ， $\theta+1$ 不小于 $x_{(n)}$ ，都可使 L 达到最大。

也即 $x_{(n)}-1 \leq \theta \leq x_{(1)}$ 时，都可使 L 达到最大。

故 θ 的最大似然估计是区间 $[X_{(n)}-1, X_{(1)}]$ 中任一值。

此例说明最大似然估计有时不唯一。




特殊情形总结

当似然函数是参数的严格单调函数时，利用似然函数的定义直观得到参数的最大似然估计。

(1) 似然函数是参数的严格单调**增**函数时，参数最大似然估计值取其取值范围内**最大值点**。

(2) 似然函数是参数的严格单调**减**函数时，参数最大似然估计值取其取值范围内**最小值点**。

(3) 似然函数是参数的**常**函数时，参数最大似然估计值取其取值范围内**任**一点。



例10 (p47例2.14) 设总体 X 服从柯西分布, 其分布密度为

$$f(x, \theta) = \frac{1}{\pi[1 + (x - \theta)^2]}, \quad -\infty < x < +\infty,$$

解 由分布可知, 其似然函数为

$$L(\theta) = \prod_{i=1}^n \frac{1}{\pi[1 + (x_i - \theta)^2]}$$

$$\frac{d \ln L(\theta)}{d \theta} = \sum_{i=1}^n \frac{x_i - \theta}{1 + (x_i - \theta)^2} = 0$$

此方程只能求解其数值解, 可以以样本中位数为初始值进行迭代。又因为此分布均值不存在, 不能用矩估计。



4. 最大似然估计的性质

定理2.4 设 $\hat{\theta}$ 是 θ 的最大似然估计, 如果函数 $g(\theta)$ 是 $\theta \in \Theta$ 的连续函数, 则 $g(\hat{\theta})$ 是 $g(\theta)$ 的最大似然估计.

此性质可以推广到总体分布中含有多个未知参数的情况.

例10 (p48例2.16) 设总体 $X \sim N(\mu, \sigma^2)$, μ, σ^2 为未知参数, x_1, x_2, \dots, x_n 是来自 X 的一个样本值, 求 $g(\mu, \sigma^2) = P\{X > 2\}$ 的最大似然估计.


解
$$g(\mu, \sigma^2) = P\{X > 2\} = 1 - P\{X \leq 2\}$$



$$= 1 - P\left\{\frac{X - \mu}{\sigma} \leq \frac{2 - \mu}{\sigma}\right\} = 1 - \Phi\left(\frac{2 - \mu}{\sigma}\right)$$

而 μ 和 σ^2 的最大似然估计为 \bar{X}, S_n^2 , 同时 $\Phi(\mu, \sigma^2)$ 为连续函数, 因而 $g(\mu, \sigma^2)$ 的最大似然估计为

$$g(\hat{\mu}, \hat{\sigma}^2) = 1 - \Phi\left(\frac{2 - \bar{X}}{S_n}\right)$$



定理2.5 设 $T = T(X_1, X_2, \dots, X_n)$ 为 θ 的任一充分统计量, 则 θ 的最大似然估计 $\hat{\theta}$ 一定可以表示成 T 的函数.

证 由因子分解定理可知

$$L(\theta) = h(x_1, x_2, \dots, x_n)g(T(x_1, x_2, \dots, x_n), \theta)$$

其中 h 与 θ 无关, 因此, 最大化 $L(\theta)$ 等于最大化 $g(T, \theta)$, 因此, 最大似然估计 $\hat{\theta}$ (若存在)一定是 T 的函数.

注 该定理说明最大似然估计是充分统计量的函数。

通常, 最大似然估计是渐近正态估计, 也是相合估计。



Thank You!