



## **2.3 最小方差无偏估计和有效估计**

**一、最小方差无偏估计**

**二、有效估计**



# 一、最小方差无偏估计

最小方差无偏估计在均方误差意义下是一种最优估计.如何寻求此种估计, 非常有意义.

## 1 最小方差无偏估计的判别法

定理2.7 设  $\hat{\theta}(X)$  是  $\theta$  的一个无偏估计,  $D(\hat{\theta}) < \infty$ ,  
若对任何满足条件:  $EL(X) = 0, DL(X) < \infty$  的统计量  $L(X)$ , 有

$$E(L(X)\hat{\theta}(X)) = 0$$



则  $\hat{\theta}(X)$  是  $\theta$  的 *MVUE*, 其中  $X = (X_1, X_2, \dots, X_n)^T$ .



**证** 设  $\hat{\theta}_1(X)$  是  $\theta$  的任一个方差有限的无偏估计,

$$\text{令 } L(X) = \hat{\theta}_1(X) - \hat{\theta}(X)$$

显然  $EL(X) = E(\hat{\theta}_1(X) - \hat{\theta}(X)) = 0$ , 且方差有限, 同时

$$D\hat{\theta}_1(X) = D(L(X) + \hat{\theta}(X))$$


$$= DL(X) + D\hat{\theta}(X) + 2\text{cov}(L(X), \hat{\theta}(X))$$

$$= DL(X) + D\hat{\theta}(X) + 2 \left( \underline{EL(X)\hat{\theta}(X)} - \underline{EL(X)E\hat{\theta}(X)} \right)$$

$$= D[L(X)] + D[\hat{\theta}(X)] \geq D[\hat{\theta}(X)] \quad \begin{array}{c} \downarrow \\ \boxed{= \underline{EL(X)\hat{\theta}(X)} - \theta \underline{EL(X)} = 0} \end{array}$$

因而,  $\hat{\theta}(X)$  是  $\theta$  的 *MVUE*.

**0**



例1 (p54例2. 20) 设 $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 $N(\mu, \sigma^2)$ 的一个样本, 已知 $\bar{X}$ 和 $S_n^{*2}$ 是 $\mu$ 和 $\sigma^2$ 的无偏估计, 证明 $\bar{X}$ 和 $S_n^{*2}$ 分别是 $\mu$ 和 $\sigma^2$ 的MVUE.

**证** 先证明 $\bar{X}$ 是 $\mu$ 的MVUE.

设 $L(X)$ 满足 $\underline{EL(X)} = 0$ , 则

$$\int \cdots \int L \cdot \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx = 0$$

两边关于 $\mu$ 求导, 则

$$\underline{D\hat{\theta}_1(X)} = D(L(X) + \hat{\theta}(X)) \quad (1)$$

因而  $\underline{E(L(X)\bar{X})} = 0$  得证。



再证明 $S_n^{*2}$ 是 $\sigma^2$ 的MVUE.

对  $\int \cdots \int L \cdot \sum_{i=1}^n x_i \cdot \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0$  (1)

关于 $\mu$ 再求导数, 则得

$$\int \cdots \int L \cdot \left( \sum_{i=1}^n x_i \right)^2 \cdot \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0 \quad (2)$$

对  $\int \cdots \int L \cdot \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0$  关于  $\sigma^2$

求导数, 则

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \mu)^2 \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} dx = 0 \quad (5)$$



又由于  $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^2$ , 可得

$$\sum_{i=1}^n (x_i - \bar{x})^2 = \underbrace{\sum_{i=1}^n (x_i - \mu)^2}_{(5)} - \underbrace{n\bar{x}^2}_{(2)} + \underbrace{2n\mu\bar{x}}_{(1)} - \underbrace{n\mu^2}_{\text{条件}}.$$

$$\int \cdots \int L \cdot \sum_{i=1}^n (x_i - \bar{x})^2 \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2\right\} dx = 0$$

因而  $E(L(X)S_n^{*2}) = 0$ . 得证。

由此例可看出，利用判别定理进行判别，非常复杂。



**注** 定理2.7只是 $MVUE$ 的一个**判别法**，但无法寻求  
 $MVUE$ .

为了寻求更好的方法，需借助充分统计量甚至是  
完备统计量的概念。





## 补充条件期望

**定义** 条件分布的数学期望（若存在）称为**条件期望**，其定义如下：

$$E(X|Y=y)=\begin{cases} \sum_i x_i P(X=x_i|Y=y), & (X,Y)\text{为离散型;} \\ \int_{-\infty}^{+\infty} xp(x|y)dx, & (X,Y)\text{为连续型.} \end{cases}$$

$$E(Y|X=x)=\begin{cases} \sum_j y_j P(Y=y_j|X=x), & (X,Y)\text{为离散型;} \\ \int_{-\infty}^{+\infty} yp(y|x)dy, & (X,Y)\text{为连续型.} \end{cases}$$



**注意：**①条件期望 $E(X|Y=y)$ 是 $y$ 的函数，它与无条件期望 $E(X)$ 在计算和意义上都有区别.

②因为条件期望是条件分布的数学期望，因此它具有数学期望的一切性质. 如

$$E(aX_1 + bX_2|Y=y) = aE(X_1|Y=y) + bE(X_2|Y=y)$$

当 $X_1$ 与 $X_2$ 相互独立时，

$$E(X_1X_2|Y=y) = E(X_1|Y=y)E(X_2|Y=y).$$

等等.

$$(3) \quad E\{\phi(X,Y)|Y=y\} = E\{\phi(X,y)|Y=y\}$$

$$E\{\psi(X)\phi(X,Y)|X\} = \psi(X)E\{\phi(X,Y)|X\}$$

**定理（重期望公式）** 设 $(X, Y)$ 是二维随机变量且 $E(X)$ 存在，则

$$E(X) = E(E(X|Y)).$$

**说明：**①重期望 $E(E(X|Y))$ 公式的具体使用为

●如果 $Y$ 是离散型随机变量则 $E(E(X|Y))$ 公式为

$$E(X) = \sum_j p(Y = y_j) E(X|Y = y_j);$$

如果 $Y$ 是连续型随机变量则 $E(E(X|Y))$ 公式为

$$E(X) = \int_{-\infty}^{+\infty} p_Y(y) E(X|Y = y) dy.$$





**定理2.8** 设总体 $X$ 的分布函数为 $F(x, \theta)$ ,  $\theta \in \Theta$ 是未知参数,  $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 $X$ 的一个样本, 如果 $T = T(X_1, X_2, \dots, X_n)$ 是 $\theta$ 的充分统计量,  $\hat{\theta}$ 是 $\theta$ 的任一无偏估计, 记 $\hat{\theta}^* \stackrel{\Delta}{=} E(\hat{\theta} | T)$

则有


$$E\hat{\theta}^* = \theta, \quad \theta \in \Theta,$$
$$D\hat{\theta}^* \leq D\hat{\theta}, \quad \theta \in \Theta,$$



证明：由于  $T=T(x_1, x_2, \dots, x_n)$  是充分统计量，故其条件期望与参数  $\theta$  无关，从而条件期望  $\hat{\theta}^* = E(\hat{\theta} | T)$  也与  $\theta$  无关，并且  $\hat{\theta}^*$  是  $T$  的函数，因此， $\hat{\theta}^*$  可作为  $\theta$  的估计。

由于  $E\hat{\theta}^* = E[E(\hat{\theta} | T)] = E\hat{\theta} = \theta$ 。

则  $\hat{\theta}^*$  为  $\theta$  的无偏估计。



又由于  $D\hat{\theta} = E(\hat{\theta} - \theta)^2 = E(\hat{\theta} - \hat{\theta}^* + \hat{\theta}^* - \theta)^2$

$$= E(\hat{\theta} - \hat{\theta}^*)^2 + E(\hat{\theta}^* - \theta)^2 + 2E[(\hat{\theta} - \hat{\theta}^*)(\hat{\theta}^* - \theta)]$$
$$= E(\hat{\theta} - \hat{\theta}^*)^2 + D(\hat{\theta}^*) + 2E[(\hat{\theta} - \hat{\theta}^*)(\hat{\theta}^* - \theta)]$$

$$E[(\hat{\theta} - \hat{\theta}^*)(\hat{\theta}^* - \theta)] = E\{E[(\hat{\theta} - \hat{\theta}^*)(\hat{\theta}^* - \theta) | T]\}$$

$$= E\{(\hat{\theta}^* - \theta)E[(\hat{\theta} - \hat{\theta}^*) | T]\}$$

$$= E\{(\hat{\theta}^* - \theta)[E(\hat{\theta} | T) - E(\hat{\theta}^* | T)]\}$$

$$= E\{(\hat{\theta}^* - \theta)[E(\hat{\theta} | T) - \hat{\theta}^*]\}$$

$$= E\{(\hat{\theta}^* - \theta)[\hat{\theta}^* - \hat{\theta}^*]\} = 0$$

➡  $D(\hat{\theta}) = E(\hat{\theta} - \hat{\theta}^*)^2 + D(\hat{\theta}^*) \geq D(\hat{\theta}^*)$



**注：**定理2.8提供了一种改善无偏估计的方法，即，一个无偏估计  $\hat{\theta}$  对充分统计量的条件期望将能导出一个新的无偏估计，且它的方差更小。并且此无偏估计还一定是  $\theta$  的充分统计量的函数。

**？** 什么时候这么构造来的无偏估计是MVUE呢？



**定理2.9** 设总体 $X$ 的分布函数为 $F(x, \theta)$ ,  $\theta \in \Theta$ 是未知参数,  $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 $X$ 的一个样本, 如果 $T = T(X_1, X_2, \dots, X_n)$ 是 $\theta$ 的充分完备统计量,  $\hat{\theta}$ 是 $\theta$ 的任一无偏估计, 记 $\hat{\theta}^* \triangleq E(\hat{\theta} | T)$ 则 $\hat{\theta}^*$ 是 $\theta$ 的唯一的MVUE.





**证** 设  $\hat{\theta}_1$  和  $\hat{\theta}_2$  是  $\theta$  的任意两个无偏估计,  $T$  是充分统计量, 由定理2.8可知

$$E_{\theta}[E(\hat{\theta}_1 | T)] = E\hat{\theta}_1 = \theta, \quad E_{\theta}[E(\hat{\theta}_2 | T)] = E\hat{\theta}_2 = \theta \quad (*)$$

$$\text{及 } D_{\theta}[E(\hat{\theta}_1 | T)] \leq D\hat{\theta}_1, \quad D_{\theta}[E(\hat{\theta}_2 | T)] \leq D\hat{\theta}_2$$

$$\text{由此 } (*) \text{ 式可得 } E_{\theta}[E(\hat{\theta}_1 | T) - E(\hat{\theta}_2 | T)] = 0$$

又由于  $T$  是完备统计量, 由定义1.6

$$P\{E(\hat{\theta}_1 | T) = E(\hat{\theta}_2 | T)\} = 1$$

即  $\theta$  的充分无偏估计唯一, 由定理2.8可知  $\hat{\theta}^* = E(\hat{\theta}_1 | T)$  是 *MVUE*.



## 注 最小方差无偏估计寻找方法

1、构造一个充分完备统计量  $T(X_1, \dots, X_n)$  和一个  $\theta$  的无偏估计  $\hat{\theta}$ .


利用定理1.5寻找。

利用矩估计法或最大似然估计法寻找。

2、计算  $E(\hat{\theta} | T)$ , 即得  $\theta$  的一个  $MVUE$ .

例如

$\bar{X}$  是泊松分布  $\lambda$  的充分完备统计量, 同时也是  $\lambda$  的无偏估计, 则  $E(\bar{X} | \bar{X}) = \bar{X}$  是  $\lambda$  的一个  $MVUE$ .



例2 (p56例2. 21) 设总体  $X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$  为未知参数,  $X_1, X_2, \dots, X_n$  是来自  $X$  的一个样本, 求  $\mu$  和  $\sigma^2$  的最小方差无偏估计量.

**解** 由例1.10可知

$T = (\bar{X}, S_n^2)$  是  $(\mu, \sigma^2)$  的充分完备统计量, 因而

$$\hat{\mu} = E(\bar{X} | T) = \bar{X}, \quad \hat{\sigma}^2 = E(S_n^{*2} | T) = S_n^{*2}$$

所以

$\bar{X}, S_n^{*2}$  分别是  $\mu$  和  $\sigma^2$  的最小方差无偏估计.



例3(p56例2.22) 设总体  $X$  在  $[0, \theta]$  上服从均匀分布, 其中  $\theta (\theta > 0)$  未知,  $(X_1, X_2, \dots, X_n)$  是来自总体  $X$  的样本, 求  $\theta$  的最小方差无偏估计量.

**解** 首先寻求充分完备统计量, 样本的联合分布为

$$L(\theta) = \prod_{i=1}^n f(x_i) = \begin{cases} \frac{1}{\theta^n}, & 0 < x_{(1)} < \dots < x_{(n)} < \theta \\ 0, & \text{其他} \end{cases}$$
$$= \theta^{-n} I_{(0, \theta)}(x_{(n)})$$

其中  $I_{(0, \theta)}(x) = 1$  当  $0 < x < \theta$ , 显然  $X_{(n)}$  是  $\theta$  的充分统计量



再验证 $X_{(n)}$ 是完备统计量。

可通过验证 $X_{(n)}$ 的分布族是完备族来得到结论。

又由于 $X_{(n)}$ 的分布密度为


$$f_{X_{(n)}}(x) = \begin{cases} \frac{n}{\theta^n} x^{n-1} & 0 < x < \theta \\ 0 & \text{其他} \end{cases}$$

利用定义1.5, 若对任意一个满足

$Eg(X) = 0, \forall \theta \in \Theta$ , 的 $g(X)$ , 有

$$\int_{-\infty}^{+\infty} g(x) f_{X_{(n)}}(x) dx = \int_0^{\theta} g(x) \frac{n}{\theta^n} x^{n-1} dx = 0, \quad \forall \theta \in \Theta.$$

$$\text{即, } \int_0^{\theta} g(x) x^{n-1} dx = 0, \quad \forall \theta \in \Theta.$$



对于  $\int_0^\theta g(x)x^{n-1}dx = 0, \quad \forall \theta \in \Theta.$

两边对  $\theta$  求导, 得  $g(\theta)\theta^{n-1} = 0, \quad \forall \theta \in \Theta.$

在这里,  $\Theta = \{\theta > 0\}$ , 因此,  $g(\theta) = 0$ , 当  $\theta > 0$  时.

因此, 当  $X > 0$  时,  $g(X) = 0$ .

从而  $X_{(n)}$  的分布是完备分布族。  $X_{(n)}$  是充分完备统计量。

又由于  $E(X_{(n)}) = \int_0^\theta \frac{n}{\theta^n} x^n dx = \frac{n}{n+1} \theta$

$$E\left(\frac{n+1}{n} X_{(n)}\right) = \theta \longrightarrow \text{无偏估计}$$

所以  $E\left(\frac{n+1}{n} X_{(n)} \mid X_{(n)}\right) = \frac{n+1}{n} X_{(n)}$  是  $\theta$  的 *MVUE*.



## 二、有效估计

**问题：**无偏估计的方差是否可以任意的小？是否  
否有下界？ **Rao-Cramer不等式**可回答此问题。

### 1、Rao-Cramer不等式

**定理2.10** 设 $\Theta$ 是实数轴上的一个开区间，  
总体 $X$ 的分布密度为 $f(x; \theta)$ ,  $\theta \in \Theta$ ,  $(X_1, X_2, \dots, X_n)^T$   
是来自总体 $X$ 的一个样本,  **$T = T(X_1, X_2, \dots, X_n)$** 是  
 **$g(\theta)$ 的一个无偏估计量**, 且满足条件:

(1) 集合 $S = \{x \mid f(x; \theta) \neq 0\}$ 与 $\theta$ 无关;






积分和微分可交换运算次序

(2)  $\frac{\partial f(x; \theta)}{\partial \theta}$  存在且对  $\Theta$  中一切  $\theta$  有

$$\frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} f(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial f(x; \theta)}{\partial \theta} dx,$$

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \cdots, x_n) L(x, \theta) dx_1 dx_2 \cdots dx_n \\ &= \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} T(x_1, x_2, \cdots, x_n) \frac{\partial}{\partial \theta} L(x, \theta) dx_1 dx_2 \cdots dx_n \end{aligned}$$

其中  $L(x, \theta) = \prod_{i=1}^n f(x_i; \theta)$ ;


$$(3) \quad I(\theta) = E\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2 > 0$$

则对一切  $\theta \in \Theta$ , 有  $D(T(X)) \geq \frac{(g'(\theta))^2}{nI(\theta)}$ , 其中

$\frac{(g'(\theta))^2}{nI(\theta)}$  为 Rao - Cramer 下界。

特别是当  $g(\theta) = \theta$  时, 有  $D(T(X)) \geq \frac{1}{nI(\theta)}$ .

结论: 无偏估计量的方差不可以无限小, 存在下界。当其方差达到下界, 它一定是 MVUE. 但最小方差无偏估计不一定达到下界。



证

由统计量 $T(X)$ 的无偏性可知:

$$ET(X) = \int T(x)L(x, \theta)dx = g(\theta)$$

因而

$$\int T(x) \frac{\partial L(x, \theta)}{\partial \theta} dx = g'(\theta) \quad (1)$$

又由于

$$\int L(x, \theta) dx = 1$$

$$\Rightarrow g(\theta) \int \frac{\partial L(x, \theta)}{\partial \theta} dx = 0 \quad (2)$$

联立(1),(2)  $\Rightarrow \int (T(x) - g(\theta)) \frac{\partial L(x, \theta)}{\partial \theta} dx = g'(\theta)$



改写

$$\int (T(x) - g(\theta)) \frac{\partial L(x, \theta)}{\partial \theta} dx = g'(\theta)$$

$$\rightarrow g'(\theta) = \int \underbrace{\{(T(x) - g(\theta))\sqrt{L(x, \theta)}\}}_{\text{Term 1}} \underbrace{\left\{ \frac{\sqrt{L(x, \theta)}}{L(x, \theta)} \frac{\partial L(x, \theta)}{\partial \theta} \right\}}_{\text{Term 2}} dx$$

由施瓦兹不等式可知  $E|XY| \leq \sqrt{E(|X|^2)E(|Y|^2)}$

$$(g'(\theta))^2 \leq \int \{(T(x) - g(\theta))^2 L(x, \theta) dx$$

$$\begin{aligned} & \times \int \frac{1}{L(x, \theta)} \left( \frac{\partial L(x, \theta)}{\partial \theta} \right)^2 dx \\ & = D(T(X)) \times \int \frac{1}{L(x, \theta)} \left( \frac{\partial L(x, \theta)}{\partial \theta} \right)^2 dx \\ & = D(T(X)) \times \int \left( \frac{\partial \ln L(x, \theta)}{\partial \theta} \right)^2 L(x, \theta) dx \end{aligned}$$



$$= D(T(X)) \times \int \left( \frac{\partial \ln L(x, \theta)}{\partial \theta} \right)^2 L(x, \theta) dx$$


$$(g'(\theta))^2 \leq D(T(X)) \times E \left( \frac{\partial \ln L(x, \theta)}{\partial \theta} \right)^2$$

因而有

$$D(T(X)) \geq \frac{(g'(\theta))^2}{E \left( \frac{\partial \ln L(x, \theta)}{\partial \theta} \right)^2} \xrightarrow{\text{red arrow}} = nI(\theta)$$


$$\text{其中 } L(x, \theta) = \prod_{i=1}^n f(x_i; \theta);$$

$$I(\theta) = E \left( \frac{\partial \ln f(X; \theta)}{\partial \theta} \right)^2$$



证  $E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2 = nI(\theta)$

$$\begin{aligned} E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2 &= E\left(\frac{\partial \sum_{i=1}^n \ln f(x_i, \theta)}{\partial \theta}\right)^2 = E\left(\sum_{i=1}^n \frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right)^2 \\ &= E\left(\sum_{i=1}^n \left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right)^2 + 2 \sum_{i=1}^n \sum_{j \neq i} \frac{\partial \ln f(x_i, \theta)}{\partial \theta} \frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right) \\ &= \underbrace{\sum_{i=1}^n E\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2}_{nI(\theta)} + \underbrace{\left(2 \sum_{i=1}^n \sum_{j \neq i} E \frac{\partial \ln f(x_i, \theta)}{\partial \theta} \frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right)}_0 \end{aligned}$$



当  $i \neq j$  时,  $E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right)\left(\frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right)$

$$= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) E\left(\frac{\partial \ln f(x_j, \theta)}{\partial \theta}\right) \quad \text{独立}$$

$$= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \int \frac{\partial \ln f(x_j, \theta)}{\partial \theta} f(x_j, \theta) dx_j$$
$$= E\left(\frac{\partial \ln f(x_i, \theta)}{\partial \theta}\right) \int \frac{\partial f(x_j, \theta)}{\partial \theta} dx_j = 0$$

则有

$$E\left(\frac{\partial \ln L(x, \theta)}{\partial \theta}\right)^2 = \sum_{i=1}^n E\left(\frac{\partial \ln f(x, \theta)}{\partial \theta}\right)^2 = nI(\theta)$$

综上所述  $D(T(X)) \geq \frac{(g'(\theta))^2}{nI(\theta)}$






## 2、Fisher信息量

设总体 $X$ 的分布密度为 $f(x, \theta)$ ,  $X = (X_1, X_2, \dots, X_n)^T$ 为其样本, 则称

或

$$\left. \begin{aligned} I(\theta) &= E\left(\frac{\partial \ln f(X; \theta)}{\partial \theta}\right)^2 \\ I(\theta) &= -E\left[\frac{\partial^2 \ln f(X; \theta)}{\partial \theta^2}\right] \end{aligned} \right\} \text{为Fisher信息量.}$$



例4(p58例2.23) 设 $X_1, X_2, \dots, X_n$ 是来自泊松分布 $P(\lambda)$ 的一个样本, 试求 $\lambda$ 的无偏估计的方差下界。

**解** 由于 $f(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda}$ ,  $E(\bar{X}) = \lambda$ ,  $D(\bar{X}) = \frac{\lambda}{n}$ ,

则 
$$I(\lambda) = E\left[\frac{\partial \ln f(X, \lambda)}{\partial \lambda}\right]^2 = E\left(\frac{\partial (X \ln \lambda - \lambda - \ln X!)}{\partial \lambda}\right)^2$$

$$= E\left(\frac{X}{\lambda} - 1\right)^2 = \frac{1}{\lambda^2} E(X - \lambda)^2 = \frac{1}{\lambda^2} D(X) = \frac{1}{\lambda}$$

罗克拉美的下界为 
$$\frac{1}{nI(\lambda)} = \frac{\lambda}{n} = D(\bar{X})$$

所以 $\lambda$ 的最小方差无偏估计为 $\bar{X}$ .




例5(p58例2.24) 设  $X_1, X_2, \dots, X_n$  是来自正态总体  $N(\mu, \sigma^2)$  的样本, 试求  $\mu$  和  $\sigma^2$  的无偏估计的方差下界.

**解**  $\ln f(x, \mu, \sigma^2) = -\ln \sqrt{2\pi} - \frac{1}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} (x - \mu)^2$

$$I(\mu) = E\left\{\frac{\partial \ln f(X, \mu, \sigma^2)}{\partial \mu}\right\}^2 = E\frac{(X - \mu)^2}{\sigma^4} = \frac{1}{\sigma^2}$$

其罗克拉美的下界为  $\frac{1}{nI(\mu)} = \frac{\sigma^2}{n} = D(\bar{X})$

所以样本均值  $\bar{X}$  为  $\mu$  的最小方差无偏估计.



又因为 
$$\frac{\partial \ln f(x, \mu, \sigma^2)}{\partial \sigma^2} = -\frac{1}{2\sigma^2} + \frac{(x - \mu)^2}{2\sigma^4}$$

$$\frac{\partial^2 \ln f(x, \mu, \sigma^2)}{\partial (\sigma^2)^2} = \frac{1}{2\sigma^4} - \frac{(x - \mu)^2}{\sigma^6}$$

$$I(\sigma^2) = -E\left\{\frac{\partial^2 \ln f(X, \mu, \sigma^2)}{\partial (\sigma^2)^2}\right\} = \frac{E(X - \mu)^2}{\sigma^6} - \frac{1}{2\sigma^4} = \frac{1}{2\sigma^4}$$

其罗--克拉美下界为 
$$\frac{1}{nI(\sigma^2)} = \frac{2\sigma^4}{n} < D(S_n^{*2}) = \frac{2\sigma^4}{n-1}$$

这是因为 
$$D\left(\frac{(n-1)S_n^{*2}}{\sigma^2}\right) = 2(n-1), \text{ 因而 } D(S_n^{*2}) = \frac{2\sigma^4}{n-1}.$$



即  $S_n^{*2}$  的方差达不到罗-克拉美下界。但是由例2知,  $S_n^{*2}$  是  $\sigma^2$  的最小方差无偏估计, 这表明最小方差无偏估计量的方差不一定能够达到罗-克拉美下界。为此, 引入**有效估计**的概念。



### 3、有效估计

定义2.8 设  $\hat{\theta}$  (或  $T(X)$ ) 是  $\theta$  (或  $g(\theta)$ ) 的一个无偏估计, 若

$$D(\hat{\theta}) = \frac{1}{nI(\theta)} \quad (\text{或 } D(T(X)) = \frac{[g'(\theta)]^2}{nI(\theta)})$$

则称  $\hat{\theta}$  (或  $T(X)$ ) 是  $\theta$  (或  $g(\theta)$ ) 的有效估计

定义2.9 设  $\hat{\theta}$  是  $\theta$  的任一无偏估计, 称  $e(\hat{\theta}) = \frac{(1/nI(\theta))}{D(\hat{\theta})}$

为估计量  $\hat{\theta}$  的效率。显然  $0 < e(\hat{\theta}) \leq 1$ 。

定义2.10 如果  $\theta$  的无偏估计量  $\hat{\theta}$  的效率满足  $\lim_{n \rightarrow \infty} e(\hat{\theta}) = 1$

则称  $\hat{\theta}$  为  $\theta$  的渐近有效估计 (量)。




如果 $\hat{\theta}$ 是 $\theta$ 的有效估计, 则它也是最小方差无偏估计。但反之却不成立。

**例6** 设 $X_1, X_2, \dots, X_n$ 是来自 $N(\mu, \sigma^2)$ 的一个样本, 证明:  $\bar{X}$ 是 $\mu$ 的有效估计量;  $S_n^{*2}$ 是 $\sigma^2$ 的渐近有效估计量。

**证** 由信息量计算公式可知:

$$\begin{aligned} I(\mu) &= E\left(\frac{\partial \ln f(X, \mu, \sigma^2)}{\partial \mu}\right)^2 = E\left(\frac{X - \mu}{\sigma^2}\right)^2 \\ &= \frac{1}{\sigma^2} \end{aligned}$$





$$e(\bar{X}) = \frac{1/(nI(\mu))}{D(\bar{X})} = \frac{\sigma^2/n}{\sigma^2/n} = 1$$

$$I(\sigma^2) = -E\left\{\frac{\partial^2 \ln f(X, \mu, \sigma^2)}{\partial(\sigma^2)^2}\right\} = \frac{E(X - \mu)^2}{\sigma^6} - \frac{1}{2\sigma^4} = \frac{1}{2\sigma^4}$$

$$D\left(\frac{(n-1)S_n^{*2}}{\sigma^2}\right) = 2(n-1), \quad \text{因此 } D(S_n^{*2}) = \frac{2\sigma^4}{n-1}$$

$$\text{所以 } e(S_n^{*2}) = \frac{1/nI(\sigma^2)}{D(S_n^{*2})} = \frac{n-1}{n} \rightarrow 1$$



例7 (p60例2. 25) 设 $X \sim B(N, p)$ ,  $X_1, X_2, \dots, X_n$ 为总体 $X$ 的一个样本, 试证 $\hat{p} = \frac{1}{N} \bar{X}$ 是 $p$ 的有效估计量。


证  $I(p) = E\left(\frac{\partial \ln f(X, p)}{\partial p}\right)^2$

$$= E\left[\frac{d[\ln C_N^X + X \ln p + (N - X) \ln(1 - p)]}{dp}\right]^2$$

$$= E\left(\frac{X}{p} - \frac{N - X}{1 - p}\right)^2 = \frac{1}{p^2(1 - p)^2} E(X - Np)^2$$

$$= \frac{Np(1 - p)}{p^2(1 - p)^2} = \frac{N}{p(1 - p)}$$

$$D(\hat{p}) = \frac{D(\bar{X})}{N^2} = \frac{p(1 - p)}{Nn} \quad e(\hat{p}) = \frac{1/(nI(p))}{D(\hat{p})} = 1 \quad \text{得证。}$$




**定理2.11** 设总体 $X$ 的分布函数为 $F(x, \theta)$ ,  $\theta \in \Theta$ 是未知参数,  $X = (X_1, X_2, \dots, X_n)^T$ 是来自总体 $X$ 的一个样本, 如果 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是 $\theta$ 的无偏估计量, 则 $\hat{\theta}$ 是 $\theta$ 的有效估计的充分必要条件为:

1、 $\hat{\theta}$ 是 $\theta$ 的充分估计量;

2、
$$\frac{\partial \ln L(x, \theta)}{\partial \theta} = C(\theta)[\hat{\theta}(x_1, x_2, \dots, x_n) - \theta]$$

其中 $L(x, \theta)$ 是样本的联合分布密度,  $C(\theta)$ 仅依赖参数 $\theta$ .  
证明从略。

定理表明, 最大似然估计如果是充分统计量, 则一定是有效估计量。




例8 (p61例2. 26) 设  $X$  服从两点分布  $B(1, p)$ ,  $X_1, X_2, \dots, X_n$  是来自  $X$  的一个样本, 证明  $p$  的最大似然估计量是有效估计.

**解** 因为  $X$  的分布律为

$$P\{X = x\} = p^x (1 - p)^{1-x} \quad (x = 0, 1)$$

所以  $p$  的似然函数为

$$L(p) = \prod_{i=1}^n \left( p^{x_i} (1 - p)^{1-x_i} \right) = p^{\sum_{i=1}^n x_i} (1 - p)^{n - \sum_{i=1}^n x_i}$$


$$\ln L(p) = \left( \sum_{i=1}^n x_i \right) \ln p + \left( n - \sum_{i=1}^n x_i \right) \ln(1-p),$$

$$\frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = \frac{n}{p(1-p)} (\bar{x} - p) = 0$$

解得  $p$  的最大似然估计值  $\hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x},$

$$\frac{d}{dp} \ln L(p) = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = \frac{n}{p(1-p)} (\bar{x} - p)$$

$C(p)$

$\bar{X}$ 是 $p$ 的充分统计量。 有效估计量



Thank You!