

3.4 minimax估计

一、 minimax决策函数

二、 计算minimax决策函数步骤

三、 利用贝叶斯估计计算最小最大决策函数



一、minimax决策函数

在贝叶斯决策中，通常以风险函数最小为衡量标准。但有的时候人们处于保守考虑，决策时考虑最坏情形，即风险最大时寻找最佳策略——最小最大决策。


定义3.12 给定一个统计决策问题，设 D^* 是由全体决策函数组成的类，如果存在一个决策函数 $d^* = d^*(x_1, x_2, \dots, x_n), d^* \in D^*$ ，使得对任意一个决策 $d = d(x_1, x_2, \dots, x_n)$ ，总有

$$\max_{\Theta} R(\theta, d^*) \leq \max_{\Theta} R(\theta, d), \quad \forall d \in D^*$$

则称 d^* 为统计决策问题的最小最大决策函数。

注 函数达不到最大值时，可以理解为上确界。

以最大风险的大小作为衡量决策函数好坏的准则.使**最大风险达到最小**的决策函数就是考虑到最不利的情况，要求最不利的情况尽可能好。



如果我们讨论的统计决策问题是一个估计问题，
则由定义3.12得到的决策函数为最小最大估计量。
下面介绍寻求最小最大决策函数的一般步骤

二、计算minimax决策函数的步骤

计算minimax决策函数的步骤：

1、对 D^* 中每个决策函数 $d(x_1, x_2, \dots, x_n)$ ，求出其风险函数在 Θ 上的最大风险值 $\max_{\Theta} R(\theta, d)$ 。

2、在所有最大风险值中选取相对最小值，此值对应的决策函数便是最小最大决策函数。

例1 (p107例3. 17) 地质学家要根据某地区的底层结构来判断该地是否蕴藏有石油，地层结构 x 总是0,1两种状态之一，记该地层无油 θ_0 ，记该地层有油为 θ_1 ，已知为它们的分布规律如下表所示

石油状态 ← θ	x	0	1
	θ_0	0.6	0.4
	θ_1	0.3	0.7

土地所有者希望根据地质学家对地层的分析来决策：

$a_1 = \{\text{自己投资钻探石油}\}$ $a_2 = \{\text{出卖土地所有权}\}$

$a_3 = \{\text{该地区开辟旅游景点}\}$

3种决策对应的
的损失函数为

$\theta \backslash x$	0	1
θ_0	0.6	0.4
θ_1	0.3	0.7

$L(\theta, a) \backslash a$	a_1	a_2	a_3
θ_0	12	1	6
θ_1	0	10	5

现在选用9个决策函数

x	$d_1(x)$	$d_2(x)$	$d_3(x)$	$d_4(x)$	$d_5(x)$	$d_6(x)$	$d_7(x)$	$d_8(x)$	$d_9(x)$
0	a_1	a_1	a_1	a_2	a_2	a_2	a_3	a_3	a_3
1	a_1	a_2	a_3	a_1	a_2	a_3	a_1	a_2	a_3

$L(\theta, a)$ $\theta \backslash a$	a_1	a_2	a_3
θ_0	12	1	6
θ_1	0	10	5

$\theta \backslash x$	0	1
θ_0	0.6	0.4
θ_1	0.3	0.7

x	$d_1(x)$	$d_2(x)$	$d_3(x)$	$d_4(x)$	$d_5(x)$	$d_6(x)$	$d_7(x)$	$d_8(x)$	$d_9(x)$
0	a_1	a_1	a_1	a_2	a_2	a_2	a_3	a_3	a_3
1	a_1	a_2	a_3	a_1	a_2	a_3	a_1	a_2	a_3

计算第四个决策函数对应的风险函数

$$\begin{aligned}
 R(\theta_0, d_4) &= L(\theta_0, a_2)P_{\theta_0}(X=0) + L(\theta_0, a_1)P_{\theta_0}(X=1) \\
 &= 1 \times 0.6 + 12 \times 0.4 = 5.4
 \end{aligned}$$

$$R(\theta_1, d_4) = 10 \times 0.3 + 0 \times 0.7 = 3$$

x	$d_1(x)$	$d_2(x)$	$d_3(x)$	$d_4(x)$	$d_5(x)$	$d_6(x)$	$d_7(x)$	$d_8(x)$	$d_9(x)$
0	a_1	a_1	a_1	a_2	a_2	a_2	a_3	a_3	a_3
1	a_1	a_2	a_3	a_1	a_2	a_3	a_1	a_2	a_3

风险函数及其对应的最大值表

$d_i(x)$	d_1	d_2	d_3	d_4	d_5	d_6	d_7	d_8	d_9
$R(\theta_0, d_i)$	12	7.9	9.6	5.4	1	3	8.4	4	6
$R(\theta_1, d_i)$	0	7	3.5	3	10	6.5	1.5	8.5	5
$\max_{\theta \in \Theta} R(\theta, d_i)$	12	7.9	9.6	5.4	10	6.5	8.4	8.5	6

由最小最大决策函数的定义可知， d_4 为统计决策问题的minimax决策函数.即样本为0时，选择 a_2 ，样本为1时，选择 a_1 。

三、利用贝叶斯估计计算 最小最大决策函数

定理3.9 给定一个统计决策问题，如果存在某个先验分布，使得在这个先验分布下的贝叶斯决策函数 $d_B(x_1, x_2, \dots, x_n)$ 的风险函数为一个常数，那么 $d_B(x_1, x_2, \dots, x_n)$ 必定是这个统计决策问题的一个最小最大决策函数。

证 反证法 设 $d_B(x_1, x_2, \dots, x_n) = d_B$ 的风险函数

$$R(\theta, d_B) = C, \quad \forall \theta \in \Theta,$$

因而它的贝叶斯风险为

$$R_B(d_B) = C. (\text{常数的期望是常数本身})$$

假设 $d_B(x_1, x_2, \dots, x_n)$ 不是最小最大决策函数，
那么必定有一个决策函数 $d^*(x_1, x_2, \dots, x_n)$ ，使得

$$\max_{\theta \in \Theta} R(\theta, d^*) = R_M(d^*) < R_M(d_B) = C$$

于是， $d^*(x_1, x_2, \dots, x_n)$ 的风险函数满足

$$R(\theta, d^*) \leq R_M(d^*) < C, \quad \forall \theta \in \Theta,$$

对上式在给定的先验分布下求期望，

$$R_B(d^*) = E_{\theta}(R(\theta, d^*)) < C = R_B(d_B),$$

这表明 d_B 不可能是这个先验分布下的贝叶斯决策函数，
从而产生矛盾，因此 d_B 必定是一个minimax决策函数。

某先验分布下，风险函数是常数的
贝叶斯决策函数也是minimax决策函数。

例2 (p109例3.18) 设总体 X 服从两点分布 $B(1, p)$, 其中参数 p 未知, 而 p 在 $[0, 1]$ 上服从 β 分布 $\beta(\frac{\sqrt{n}}{2}, \frac{\sqrt{n}}{2})$, (X_1, X_2, \dots, X_n) 来自总体 X , 损失函数为平方损失, 则参数 p 的贝叶斯估计为 p 的minimax估计。

解 平方损失下的贝叶斯估计为:

$$d^*(x) = E(p | X = x) = \int_{\Theta} p h(p | x) dp$$

$$\text{而 } h(p | x) = \frac{q(x | p)\pi(p)}{m(x)} = \frac{q(x | p)\pi(p)}{\int_0^1 q(x | p)\pi(p) dp}$$

$$= \frac{p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \cdot \pi(p)}{\int_0^1 p^{\sum_{i=1}^n x_i} (1-p)^{n-\sum_{i=1}^n x_i} \cdot \pi(p) dp}$$

$$= \frac{p^{\sum_{i=1}^n x_i + \frac{\sqrt{n}}{2} - 1} (1-p)^{n - \sum_{i=1}^n x_i + \frac{\sqrt{n}}{2} - 1}}{\beta(\sum_{i=1}^n x_i + \frac{\sqrt{n}}{2}, n + \frac{\sqrt{n}}{2} - \sum_{i=1}^n x_i)}$$

$$\text{显然 } p | x \sim \beta(\sum_{i=1}^n x_i + \frac{\sqrt{n}}{2}, n + \frac{\sqrt{n}}{2} - \sum_{i=1}^n x_i)$$

$$\hat{p} = d^*(x) = \int_{\Theta} p h(p | x) dp = \frac{2\sqrt{n}\bar{X} + 1}{2(\sqrt{n} + 1)}$$



\hat{p} 的风险函数为

$$\begin{aligned} R(p, \hat{p}) &= E\left(\frac{2\sqrt{n}\bar{X} + 1}{2(\sqrt{n} + 1)} - p\right)^2 \\ &= D\left(\frac{2\sqrt{n}\bar{X} + 1}{2(\sqrt{n} + 1)}\right) + \left(E\left(\frac{2\sqrt{n}\bar{X} + 1}{2(\sqrt{n} + 1)} - p\right)\right)^2 \\ &= \frac{4n}{4(\sqrt{n} + 1)^2} \cdot \frac{p(1-p)}{n} + \left(\frac{2\sqrt{n}p + 1}{2(\sqrt{n} + 1)} - p\right)^2 \\ &= \frac{1}{4(\sqrt{n} + 1)^2} \quad (\text{常数}) \end{aligned}$$

因而其为minimax估计.

定理3.10 给定一个贝叶斯决策问题，设 $\{\pi_k(\theta): k \geq 1\}$ 为参数空间 Θ 上的一个先验分布列， $\{d_k: k \geq 1\}, \{R_B(d_k): k \geq 1\}$ 分别为相应的贝叶斯估计列和贝叶斯风险列，若 d_0 是 θ 的一个估计，且它的风险函数 $R(\theta, d_0)$ 满足

$$\max_{\theta \in \Theta} R(\theta, d_0) \leq \lim_{n \rightarrow \infty} R_B(d_k)$$

则 d_0 为 θ 的 minimax 估计.

证 反证法 设 d_0 不是 θ 的最小最大估计，则存在一个估计 d ，使得 $\max_{\theta \in \Theta} R(\theta, d) < \max_{\theta \in \Theta} R(\theta, d_0)$

由于 d_k 是在先验分布 $\pi_k(\theta)$ 下的贝叶斯估计，故其贝叶斯风险最小，因而

$$R_B(d_k) \leq R_B(d) = \int_{\Theta} R(\theta, d) \pi_k(\theta) d\theta \leq \max_{\theta \in \Theta} R(\theta, d)$$

由此可以得到

$$< \max_{\theta \in \Theta} R(\theta, d_0)$$

$$R_B(d_k) < \max_{\theta \in \Theta} R(\theta, d_0), \quad k \geq 1$$

则

$$\lim_{k \rightarrow \infty} R_B(d_k) < \max_{\theta \in \Theta} R(\theta, d_0)$$

显然这与定理条件矛盾，因此

d_0 是 θ 的最小最大估计。

定理3.11 给定一个贝叶斯决策问题, 若 θ 的一个估计 d_0 的风险函数 $R(\theta, d_0)$ 在 Θ 上为常数 ρ , 且存在一个先验分布列 $\{\pi_k(\theta) : k \geq 1\}$, 使得相应的贝叶斯估计 d_k 的贝叶斯风险满足

$$\lim_{k \rightarrow \infty} R_B(d_k) = \rho$$

则 d_0 为 θ 的 minimax 估计.

证 对任意的 $\theta \in \Theta$, 有

$$\max_{\theta \in \Theta} R(\theta, d_0) = R(\theta, d_0) = \rho = \lim_{k \rightarrow \infty} R_B(d_k)$$

显然满足了定理3.10, 因而 d_0 是 θ 的最小最大估计.

例3 (p111例3.19) 设 $X = (X_1, X_2, \dots, X_n)^T$ 为来自正态总体 $N(\theta, 1)$ 的一个样本, 取参数 θ 的先验分布为正态分布 $N(0, \tau^2)$, 其中 τ 已知, 损失函数取为

$$L(\theta, d) = \begin{cases} 1, & |d - \theta| > \varepsilon, \quad \varepsilon > 0 \\ 0, & |d - \theta| \leq \varepsilon, \quad \varepsilon > 0 \end{cases}$$

其对应的参数 θ 的贝叶斯估计为

$$d_\tau(X) = \left(\frac{1}{n} \sum_{i=1}^n X_i \right) \left(1 + \frac{1}{n\tau^2} \right)^{-1}$$

试用定理3.11证明 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 是 θ 的最小最大估计.

证明 (1) 先计算 \bar{X} 的风险函数为常数值。

$$\text{因为 } \bar{X} \sim N(\theta, \frac{1}{n})$$

$$R(\theta, \bar{X}) = EL(\theta, \bar{X})$$

$$= P(|\bar{X} - \theta| \geq \varepsilon) = 1 - P(\theta - \varepsilon < \bar{X} < \theta + \varepsilon)$$

$$= 1 - P\left(-\frac{\varepsilon}{\sqrt{\frac{1}{n}}} < \frac{\bar{X} - \theta}{\sqrt{\frac{1}{n}}} < \frac{\varepsilon}{\sqrt{\frac{1}{n}}}\right)$$

$$= 1 - P_{\theta}(-\sqrt{n}\varepsilon < \sqrt{n}(\bar{X} - \theta) < \sqrt{n}\varepsilon)$$

$$= 1 - \Phi(\sqrt{n}\varepsilon) + \Phi(-\sqrt{n}\varepsilon) = 2 - 2\Phi(\sqrt{n}\varepsilon) = \rho$$

(2) 再计算 θ 的贝叶斯估计。由例3.15知 θ 的后验分布 $h(\theta | x)$ 为正态分布

$$N\left(\sum_{i=1}^n X_i (n + \tau^{-2})^{-1}, (n + \tau^{-2})^{-1}\right) \\ = N\left(\bar{X} \left(1 + \frac{1}{n\tau^2}\right)^{-1}, (n + \tau^{-2})^{-1}\right).$$

对任一决策函数 d 其后验风险为

$$R(d | x) = \int_{-\infty}^{+\infty} L(\theta, d) h(\theta | x) d\theta = P_{\theta}\{|d - \theta| > \varepsilon\} \\ = 1 - P_{\theta}\{|d - \theta| \leq \varepsilon\}.$$

要使上述后验风险最小，就要使上式中概率

$P_{\theta}\{|d - \theta| \leq \varepsilon\}$ 最大，因此 $d(X)$ 只能取后验分布的均值，即

在对应损失函数下，参数 θ 的贝叶斯估计为

$$d_{\tau}(X) = \bar{X} \left(1 + \frac{1}{n\tau^2}\right)^{-1}$$

与 τ 有关

(3)构造一个先验分布列和一个贝叶斯估计列

先验分布列 $\{\pi_k(\theta): k \geq 1\}$ 选取为 $\{N(0, \tau_i^2): \tau_1 < \dots < \tau_i < \dots\}$,

相应的贝叶斯估计列为 $\{d_{\tau_i}(X), i = 1, 2, \dots\}$.

因为 $\bar{X} \sim N(\theta, \frac{1}{n})$

所以 $d_{\tau_i}(X) = \bar{X} \left(1 + \frac{1}{n\tau_i^2}\right)^{-1} \sim N\left(\theta \left(1 + \frac{1}{n\tau_i^2}\right)^{-1}, \frac{1}{n} \left(1 + \frac{1}{n\tau_i^2}\right)^{-2}\right)$

则 d_τ 的风险函数为

$$\begin{aligned}
 R(\theta, d_\tau) &= P(|d_\tau - \theta| \geq \varepsilon) = 1 - P(\theta - \varepsilon < d_\tau < \theta + \varepsilon) \\
 &= 1 - P\left(\frac{\theta - \varepsilon - \theta(1 + \frac{1}{n\tau_i^2})^{-1}}{\sqrt{\frac{1}{n}(1 + \frac{1}{n\tau_i^2})^{-2}}} < \frac{d_\tau - \theta(1 + \frac{1}{n\tau_i^2})^{-1}}{\sqrt{\frac{1}{n}(1 + \frac{1}{n\tau_i^2})^{-2}}} < \frac{\theta + \varepsilon - \theta(1 + \frac{1}{n\tau_i^2})^{-1}}{\sqrt{\frac{1}{n}(1 + \frac{1}{n\tau_i^2})^{-2}}}\right) \\
 &= 2 - \Phi\left(\sqrt{n}\left[\varepsilon\left(1 + \frac{1}{n\tau^2}\right) + \frac{\theta}{n\tau^2}\right]\right) - \Phi\left(\sqrt{n}\left[\varepsilon\left(1 + \frac{1}{n\tau^2}\right) - \frac{\theta}{n\tau^2}\right]\right)
 \end{aligned}$$

显然

$$\lim_{\tau \rightarrow \infty} R(\theta, d_{\tau}) = 2 - 2\Phi(\sqrt{n\varepsilon}) \text{ (常数)}$$

对序列 $\tau_1 < \cdots < \tau_i < \cdots \rightarrow \infty$, 有 $R(\theta, d_{\tau_i}) < 2$, 于是利用勒贝格控制收敛定理知 有界

$$\begin{aligned} \lim_{i \rightarrow \infty} R_B(d_{\tau_i}) &= \lim_{i \rightarrow \infty} E_{\theta}(R(\theta, d_{\tau_i})) = E_{\theta} \lim_{i \rightarrow \infty} R(\theta, d_{\tau_i}) \\ &= E_{\theta}[2 - 2\Phi(\sqrt{n\varepsilon})] = 2[1 - \Phi(\sqrt{n\varepsilon})] = R(\bar{X}_n) = \rho \end{aligned}$$

因而由定理3.11可知, \bar{X}_n 是 θ 的最小最大估计.

Thank You!

